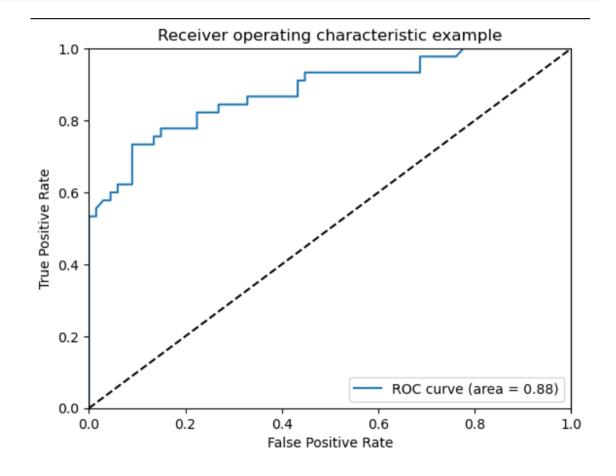
Data Robot Outputs

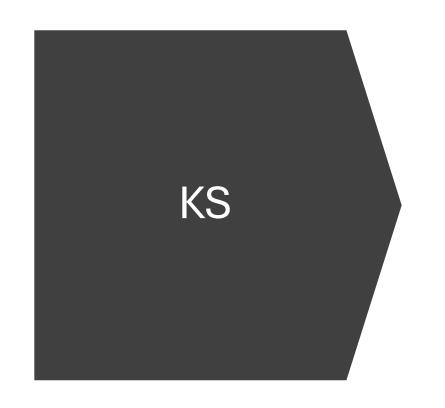
Pepper Money

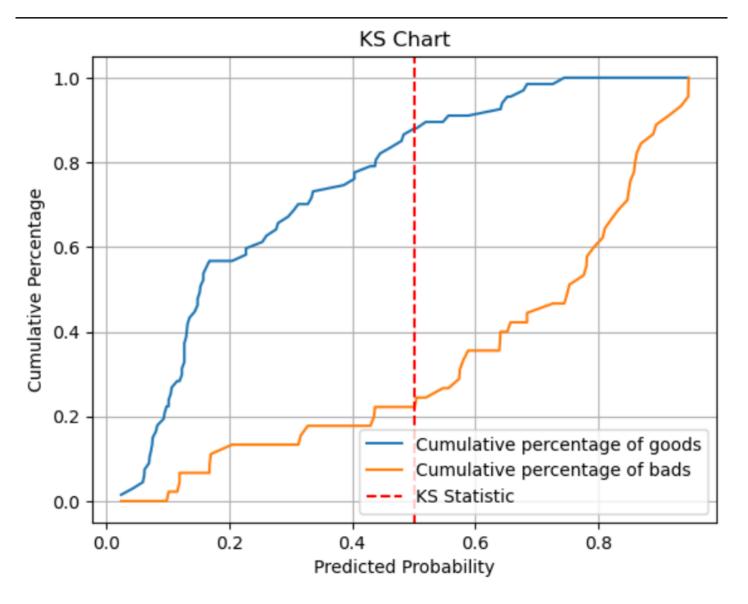
- Distribución de Predicciones y Curva ROC:
- Profundiza en el rendimiento del modelo seleccionado (M132). La Curva ROC muestra un buen poder discriminativo general del modelo.
- Sin embargo, al observar la Matriz de Confusión y las Métricas de Rendimiento (F1 Score, Tasa de Verdaderos Positivos, Valor Predictivo Positivo), se revela que el modelo, en el umbral actual (0.0758), tiene dificultades para identificar correctamente los casos positivos (baja Sensibilidad y Precisión) y presenta una tasa relativamente alta de falsos positivos.
- La distribución de predicciones muestra una separación decente de las clases.

De Accuracy a AUC

```
print (pd.crosstab(y_test.Survived
                     ,y_pred_flag
                     ,rownames = ['Actual']
                     ,colnames = ['Predicted']))
   print ('\n \n')
   print(classification_report(y_test,y_pred_flag))
Predicted False True
Actual
0.0
             65
                     2
                    26
1.0
             19
             precision
                          recall f1-score support
        0.0
                  0.77
                            0.97
                                      0.86
                                                  67
        1.0
                                      0.71
                                                  45
                  0.93
                            0.58
                                                 112
   accuracy
                                      0.81
                                      0.79
                                                 112
  macro avg
                  0.85
                            0.77
weighted avg
                  0.84
                            0.81
                                      0.80
                                                 112
```







Métrica	Casos de Uso Principales	¿Requiere Umbral Fijo?	Notas Adicionales		
Exactitud (Accuracy)	Conjuntos de datos <u>balanceados</u> , donde falsos positivos y falsos negativos son igual de importantes .	Sí	Mide la proporción de predicciones correctas sobre el total.		
Precisión	Cuando los falsos positivos son más costosos o críticos (ej. detección de spam, evitar falsas alarmas).	Sí	Mide la proporción de verdaderos positivos sobre el total de positivos predichos.		
Exhaustividad (Recall)	Cuando los falsos negativos son más costosos o críticos (ej. diagnóstico médico, no perder casos importantes).	Sí	Mide la proporción de verdaderos positivos sobre el total de casos positivos reales.		
F1-score	Conjuntos de datos desbalanceados donde tanto precisión como exhaustividad son importantes.	Sí	Es la media armónica de precisión y exhaustividad; equilibra ambas métricas, dando más peso a la más baja.		
AUC	Evalúa el rendimiento general del modelo, especialmente en datasets desbalanceados . Importante cuando el umbral óptimo es desconocido o puede variar posteriormente (ej. detección de fraude, campañas de marketing según presupuesto).	No	Considera la capacidad del modelo para clasificar instancias correctamente, sin depender de un umbral específico. Útil cuando precisión y exhaustividad son importantes y el umbral puede ajustarse tras el despliegue.		
KS	Evalúa el rendimiento general del modelo, especialmente en datasets desbalanceados . Importante cuando el umbral óptimo es desconocido pero estable (ej. riesgo de crédito, modelos de rentabilidad), situándose en un rango pequeño tras el despliegue.	No	Considera la capacidad del modelo para clasificar instancias en el punto de corte óptimo (máxima diferencia entre las curvas de las dos clases). Útil cuando precisión y exhaustividad son importantes y el umbral se definirá en un rango específico y estable.		

Comparación de Modelos:

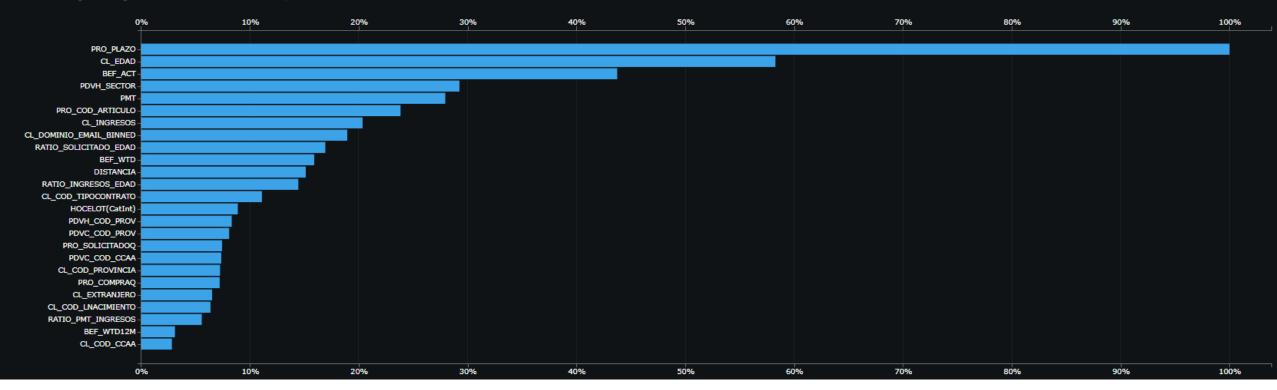
M59 BP55 SCORING CODE

- "leaderboard" de diferentes variaciones de modelos "eXtreme Gradient Boosted Trees", destacando un modelo específico (M132) como "RECOMENDADO PARA DESPLIEGUE" y "PREPARADO PARA DESPLIEGUE".
- Esto indica que DataRobot ha identificado el mejor modelo basándose en sus métricas internas y verificaciones de preparación para producción. Se observa que el proceso experimenta con diferentes conjuntos de características y afinación de hiperparámetros.

Ordinal encoding of categorical variables Missing Values Imputed eXtreme Gradient Boosted Trees Classifier with Early Stopping (Fast Feature Binning) - Forest (10x) M132 BP56 SCORING CODE MONO \$80.0%	features_from_v12.2.0 *** 100.0 % +	0.0683 *	0.0683 *	0.0683 *
Condinal encoding of categorical variables Missing Values Imputed eXtreme Gradient Boosted Trees Classifier with Early Stopping (Fast Feature Binning) - Forest (10x) M143 BP56 SCORING CODE MONO C	fix_sin_hocelot 🤫 100.0 % +	0.0682 *	0.0683 *	0.0680 *
eXtreme Gradient Boosted Trees Classifier with Early Stopping (Fast Feature Binning) - Forest (10x) Ordinal encoding of categorical variables Missing Values Imputed eXtreme Gradient Boosted Trees Classifier with Early Stopping (Fast Feature Binning) - Forest (10x) M130 BP56 SCORING CODE MONO	features_from_v12.2.0 ** 80.0 % +	0.0683 *	0.0684 *	0.0684
Continual encoding of categorical variables Missing Values Imputed eXtreme Gradient Boosted Trees Classifier with Early Stopping (Fast Feature Binning) - Forest (10x) M142 BP56 SCORING CODE MONO	fix_sin_hocelot "C 80.0 % +	0.0684 *	0.0685 *	0.0685
eXtreme Gradient Boosted Trees Classifier with Early Stopping (Fast Feature Binning) - Forest (10x) Ordinal encoding of categorical variables Missing Values Imputed eXtreme Gradient Boosted Trees Classifier with Early Stopping (Fast Feature Binning) - Forest (10x) M60 BP56 SCORING CODE MONO	features_from_v12.2.0 ** 64.0 % +	0.0682	Run	0.0683
eXtreme Gradient Boosted Trees Classifier with Early Stopping (learning rate =0.02) Ordinal encoding of categorical variables Missing Values Imputed Search for differences eXtreme Gradient Boosted Trees Classifier with Early Stopping (learning rate =0.02)	features_from_v12.2.0 ** 64.0 % +	0.0683	Run	0.0682

Feature Impact

Based on the insight's settings below, 2500 rows were used for computation.



Impacto de las Características (Feature Impact):

- Gráfico de barras revela cuáles son las variables más influyentes en las predicciones del modelo. PRO_PLAZO es, con diferencia, la característica más impactante (casi el 100%), seguida de CL_EDAD (cerca del 60%) y BEF_ACT.
- Esto proporciona información crucial sobre los factores que impulsan el resultado predicho por el modelo y puede guiar estrategias de negocio o futuras recopilaciones de datos.